Practica 15

Comparación de Modelos de Regresión: Árbol de Decisión y Random Forest para la Predicción de Sueldos

Garay Pérez Matthew Ilveneff

202210036@tesco.edu.mx

Tecnológico de Estudios Superiores de Coacalco

Ingeniería en Sistemas Computacionales

Programación Lógica Y Funcional

Ing. Vivanco Benavides Luis Enrique

Entrega 02 de junio de 2025

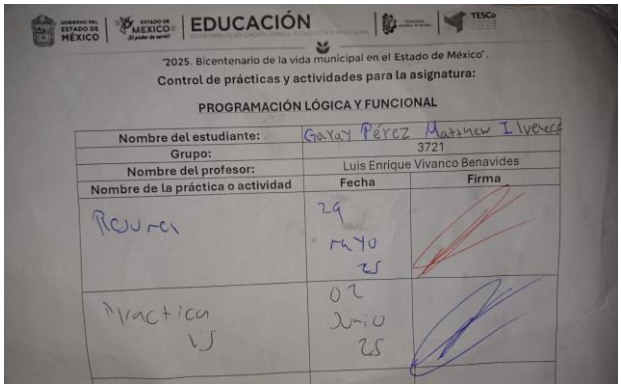
3721

Introducción

En el análisis de datos y aprendizaje automático, la regresión es una técnica fundamental para predecir variables continuas a partir de una o más variables independientes. En esta práctica se implementan y comparan dos algoritmos de regresión ampliamente utilizados: el árbol de regresión (mediante el paquete rpart) y el modelo de Random Forest, ambos aplicados a un conjunto de datos sencillo que relaciona los años de experiencia con el sueldo anual de distintas personas.

El árbol de regresión es un modelo sencillo y fácilmente interpretable, ya que segmenta los datos en función de condiciones lógicas y permite visualizar claramente el proceso de decisión. Sin embargo, su simplicidad también puede ser una desventaja, ya que tiende a sobreajustarse a los datos de entrenamiento, especialmente cuando estos son limitados (James et al., 2021). Por otro lado, el modelo de Random Forest mejora la precisión mediante la construcción de múltiples árboles y la agregación de sus predicciones, lo que reduce la varianza del modelo y lo hace más robusto (Breiman, 2001).

Esta práctica tiene como objetivo comparar el desempeño de ambos modelos utilizando el lenguaje R, evaluando tanto la calidad de las predicciones como la facilidad de interpretación. A través de visualizaciones y predicciones puntuales, se busca identificar cuál de los dos modelos es más adecuado para este tipo de problema.



EDUCACIÓN

"2025. Bicentenario de la vida municipal en el Estado de México".

Control de prácticas y actividades para la asignatura:

PROGRAMACIÓN LÓGICA Y FUNCIONAL

Nombre del estudiante:	Garay Pérez Matthew Ivanco	
Grupo:	3721	
Nombre del profesor:	Luis Enrique Vivanco Benavides	
Nombre de la práctica o actividad	Fecha	Firma
Recurci	29 mayo 25	
Practica 13	02 Junio 25	

Desarrollo

Random Forest

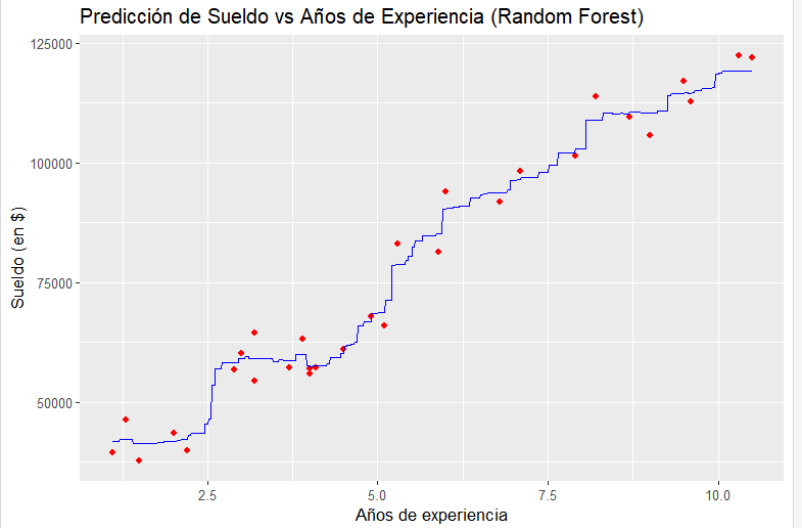
Se realiza un análisis de regresión utilizando el algoritmo Random Forest para predecir el sueldo de una persona en función de sus años de experiencia. El proceso comienza con la importación de un conjunto de datos (Salary_Data.csv) que contiene información sobre los sueldos y los años de experiencia de diferentes personas. Posteriormente, se cargan las librerías necesarias: randomForest para crear el modelo de regresión y ggplot2 para generar visualizaciones gráficas. Se establece una semilla aleatoria (set.seed(1234)) para garantizar la reproducibilidad de los resultados.

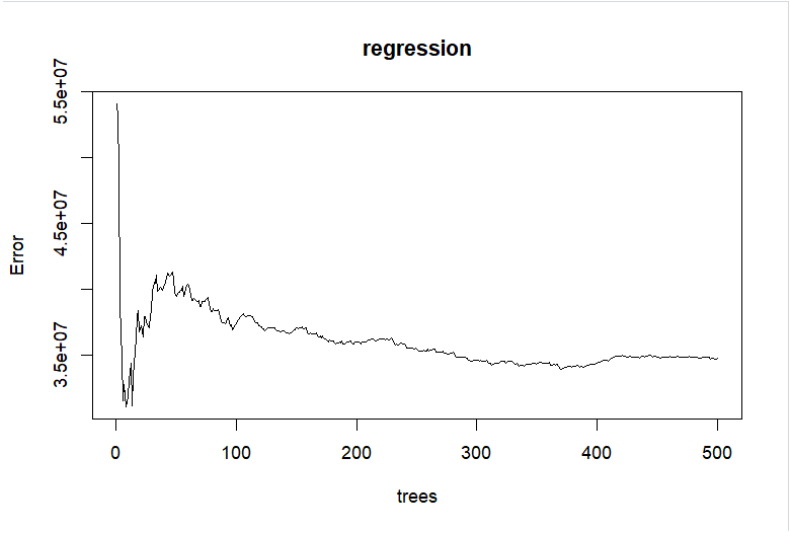
Luego, se entrena un modelo de regresión mediante Random Forest, donde la variable dependiente es el sueldo (Salary) y la independiente son los años de experiencia (YearsExperience). Se especifica que el modelo debe construirse con 500 árboles de decisión (ntree = 500), lo que busca mejorar la precisión de la predicción. Una vez entrenado el modelo, se realiza una predicción específica para una persona con 6.5 años de experiencia.

Para visualizar cómo el modelo se comporta en todo el rango de datos, se genera una secuencia de valores (x_grid) que representa los posibles años de experiencia en pasos muy pequeños (0.01), y para cada uno de estos valores se calcula la predicción correspondiente usando el modelo entrenado. Estos resultados se almacenan en un nuevo data.frame llamado plot_data.

Finalmente, se crea una visualización utilizando ggplot2, donde se muestran en rojo los datos reales del conjunto (geom_point) y en azul la curva de predicción generada por el modelo (geom_line). Esto permite observar de forma clara cómo el modelo ajusta los datos y predice los sueldos. También se muestran el resumen estadístico del modelo (summary(regression)) y

un gráfico de diagnóstico del modelo (plot(regression)), que ayudan a analizar su rendimiento y comportamiento general.






```
                Length Class  Mode
call             4     -none- call
type             1     -none- character
predicted       30     -none- numeric
mse            500     -none- numeric
rsq            500     -none- numeric
oob.times       30     -none- numeric
importance       1     -none- numeric
importanceSD     0     -none- NULL
localImportance  0     -none- NULL
proximity        0     -none- NULL
ntree            1     -none- numeric
mtry             1     -none- numeric
forest          11     -none- list
coefs            0     -none- NULL
y               30     -none- numeric
test             0     -none- NULL
inbag            0     -none- NULL
terms            3     terms  call
```

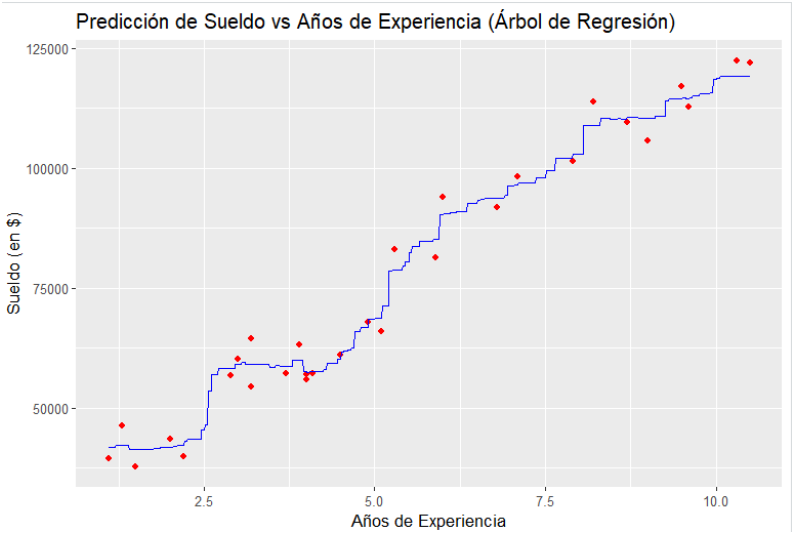
Arboles de Decisión

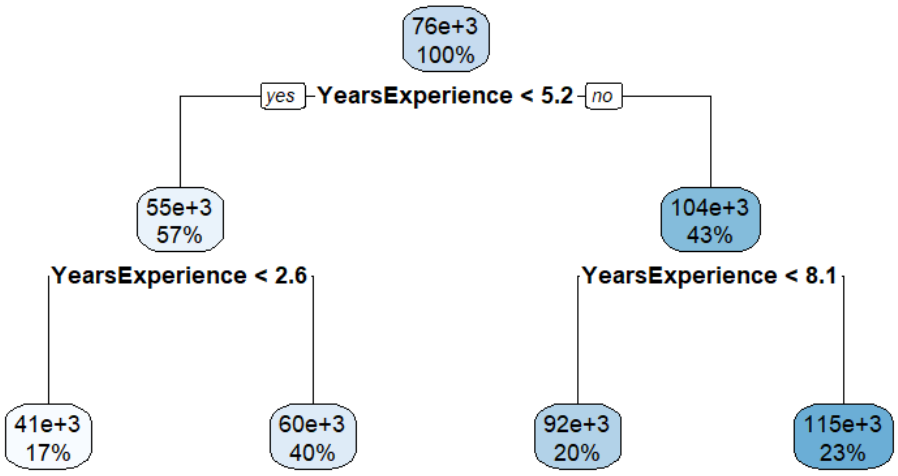
Se implementa un modelo de árbol de regresión para predecir el sueldo de una persona en función de sus años de experiencia, utilizando el dataset "Salary_Data.csv". Se cargan tres librerías esenciales: rpart para construir el árbol de decisión, ggplot2 para la visualización de datos, y rpart.plot, que permite graficar el árbol generado de manera intuitiva.

El dataset es leído y almacenado en la variable dataset2. Luego, se entrena el modelo de regresión (regression1) utilizando la función rpart, donde la fórmula indica que el sueldo (Salary) depende de todas las demás variables del dataset (representadas por el punto .). El parámetro minsplit = 10 se establece como una condición de control, lo que significa que un nodo debe tener al menos 10 observaciones para que pueda dividirse, ayudando así a evitar el sobreajuste del modelo.

Después, se realiza una predicción para una persona con 6.5 años de experiencia usando el modelo ya entrenado. Aunque esta predicción no se visualiza directamente, el código genera un gráfico con ggplot2 que representa la relación entre los años de experiencia y el sueldo. En esta visualización, los puntos rojos muestran los datos reales del conjunto original (dataset), mientras que la línea azul representa las predicciones (plot_data) generadas previamente, aunque estas predicciones en realidad provienen de un modelo distinto (Random Forest), lo cual podría generar confusión si no se actualiza esa parte del código para que use las predicciones del árbol de regresión.

Por último, se utiliza rpart.plot() para graficar visualmente el árbol de decisión construido. Este gráfico muestra cómo el modelo divide los datos en distintos nodos basados en los valores de los años de experiencia, permitiendo una interpretación clara y sencilla del proceso de predicción que realiza el árbol.





¿Qué modelo es mejor?

Entre los dos modelos aplicados al dataset Salary_Data.csv, Random Forest es generalmente la mejor opción porque ofrece mayor precisión y robustez en las predicciones, gracias a que combina múltiples árboles y reduce el riesgo de sobreajuste. Aunque el árbol de regresión (rpart) es más fácil de interpretar y visualizar, su capacidad de predicción es limitada y puede ser inestable con pocos datos. Por lo tanto, para obtener resultados más confiables al

predecir el sueldo en función de los años de experiencia, se recomienda utilizar el modelo de Random Forest.

Conclusiones

Tras la implementación y análisis de los modelos de árbol de regresión (rpart) y Random Forest sobre el conjunto de datos Salary_Data.csv, se concluye que el modelo de Random Forest ofrece un mejor desempeño en términos de precisión y robustez predictiva. Esto se debe a su naturaleza de ensamble, que permite combinar múltiples árboles de decisión y reducir la varianza del modelo, logrando así una predicción más estable y menos propensa al sobreajuste (Breiman, 2001).

Aunque el árbol de regresión presenta ventajas importantes en cuanto a interpretabilidad y visualización del proceso de decisión, sus predicciones pueden ser limitadas y menos precisas cuando se trabaja con datos que presentan relaciones no lineales o con un volumen pequeño de observaciones (James et al., 2021). Este comportamiento se reflejó en la práctica, donde Random Forest generó curvas de predicción más suaves y cercanas a la tendencia real del dataset.

Por tanto, se recomienda el uso de Random Forest para tareas de predicción cuando la prioridad es la calidad del resultado, especialmente en entornos donde se puede sacrificar algo de interpretabilidad a cambio de una mejor generalización. Sin embargo, el árbol de regresión sigue siendo útil como herramienta complementaria, sobre todo para fines explicativos o exploratorios en etapas iniciales del análisis.

Referencias Bibliográficas

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning: With Applications in R (2nd ed.). Springer. https://www.statlearning.com/